

OpenTenBase pgvector 查询路径优化

技术报告与可复现证据包

报告版本 : 2026-08-18 | run id: ivfflat-query-path-v1

1. 摘要

研究问题

本项目针对 OpenTenBase 内置 pgvector 的 IVFFlat

查询路径，研究两个相互独立但会在生产查询中同时出现的问题：重复 rescan

时排序状态和归一化查询值的生命周期是否可靠，以及高 probes 查询是否真正使用了 pgvector

原本设计的自动向量化编译能力。目标是改善稳定性和延迟，同时保持距离计算、索引计划与召回率不变。

方法与证据

源码审计定位到两处平台适配点。第一处在 rescan 生命周期：补丁在重新归一化 Cosine 查询值前释放旧值，并在 OpenTenBase PG10 基座没有 tuplesort_reset()

时采用销毁并重建排序状态的等价语义。第二处在构建链：OpenTenBase 的 in-tree 构建设没有消费 pgvector 的 PG_CFLAGS，导致上游已有的自动向量化参数被静默丢失；补丁恢复实际 CFLAGS 传递，依靠编译器生成 packed SIMD。代码中没有手写 SIMD intrinsics。

主实验固定 100,000 行、128 维、200 条 Cosine 查询，lists=1000、probes=1000、work_mem=4MB，采用五次 ABBA 配对。稳定矩阵显示优化构建平均工作负载从 20,261.376 ms 降至 16,552.993 ms，即降低 18.30%，5/5 配对更快；吞吐从 9.871 QPS 升至 12.082 QPS，即提高 22.40%。2,000 个 exact 与 IVFFlat top-10 结果逐行一致，recall@10=1.000000，差异行数为 0。perf 证据显示内积相关 self-time 合计占比从 32.80% 降至 17.37%，与机制主张一致。

rescan 消融在 10,000 和 50,000 次循环时分别使峰值 RSS 增长降低 48.35% 和 59.97%，但生命周期执行时间方向 mixed，因此不附加延迟收益。新增 ivfflat.query_work_mem=64MB 消除了每个工作负载的 69,000 个临时读块和 69,400 个临时写块，但延迟改善为 7.32%，低于 10% 主成功门槛，故被降级为可选调优控制。

结论

证据支持两项平台级发现：OpenTenBase 的 IVFFlat rescan 需要显式恢复排序状态和查询值生命周期语义；构建链中的一行标志传递差异会让上游自动向量化能力静默失效。主性能结论只适用于本报告固定的高 probes、Cosine、单机 workload；数据分布、距离类型、并发度和分布式拓扑的泛化仍需后续矩阵验证。

2. 背景与任务对齐

2.1 项目背景

OpenTenBase 将 pgvector 作为数据库内向量检索能力的一部分。IVFFlat 查询先按中心距离选择候选 list，再计算候选距离并通过 tuplesort 产生 top-k；当查询出现在嵌套循环或远程执行路径中时，同一个 scan state 会被反复 rescan。该路径同时受到查询值分配、排序状态复用、编译器优化和临时文件 I/O 的影响，单看一次 SQL 延迟无法解释全部风险。

本项目选择源码、编译产物和固定 workload 三层证据：源码确认语义变更，汇编和 perf 确认机制，重复矩阵确认结果大小。这样可以区分“修复正确性问题”“恢复平台能力”和“单纯调大内存参数”三类贡献。

2.2 任务与验收门槛

项目计划 (PLAN.md) 规定：保持固定数据生成方法、查询集合、索引参数、数据库拓扑和预热方式；正式比较至少五次重复；保存 EXPLAIN (ANALYZE, BUFFERS)、回归日志和 recall@10。主性能成功门槛是核心指标至少改善 10%、五次方向一致、召回率不下降且计划继续使用 IVFFlat。

本报告对应的已验收结果如下：

任务	证据	结论
rescan 状态可靠	performance/final-vectorized-regression.log，原始基线 3 个 invalid tuplesort state	回归通过
生命周期内存	ablation/memory-matrix-stats.csv	10,000/50,000 rescans 峰值增长分别降低 48.35%/59.97%
高 probes 延迟	performance/simd-matrix-stability/aggregate.csv	平均降低 18.30%，5/5 更快
正确性与召回	performance/vectorized-matrix/correctness.txt	2,000/2,000 一致，recall 1.0
查询排序内存	performance/query-work-mem-matrix/aggregate.csv	7.32%，低于主门槛，降级记录

2.3 贡献边界

贡献一是 OpenTenBase 对 pgvector rescan 生命周期的兼容修复，包含上游 Fix memory leak in ivfrescan 语义的移植和 PG10 排序 API 差异的独立适配。贡献二是发现并修复 OpenTenBase in-tree 构建链丢失 pgvector 自动向量化标志的问题；结果是编译器自动生成 packed SIMD，而不是新增 intrinsics。贡献三是把性能、正确性、负结果和原始日志放在同一可复现证据链中。

本项目不宣称所有 pgvector workload 都能获得 18.30% 提升，不宣称 lifecycle 修复本身降低执行时间，也不把 7.32% 的排序内存收益包装为主成果。这些限制将在第 8 章展开。

3. 环境与可复现声明

证据来源

- 远端环境：artifacts/experiment/ivfflat-query-path-v1/environment/remote-environment.txt
- 运行契约：artifacts/experiment/ivfflat-query-path-v1/run_manifest.json
- 数据清单：artifacts/experiment/ivfflat-query-path-v1/performance/data/dataset-manifest.md
- 补丁与基线：patches/series/、PLAN.md

当前写作状态

环境、编译器版本、OpenTenBase 提交、pgvector 版本、拓扑和固定种子应从上述文件逐项导入 PDF，不能由报告作者手工补写。最终版需要附环境文件的 SHA256 和一次干净复现日志。

可复现要求

报告复现必须使用同一数据规模、查询 CSV、lists/probes、预热策略和五次 ABBA 顺序。若机器、编译器或拓扑改变，结果应作为新 run 归档，不覆盖本 run。

4. 方法学

采用“源码审计 -> 机制证据 -> 重复实验 -> 正确性核验”的顺序。主比较使用五次 ABBA 配对，报告工作负载均值、每查询均值、QPS、临时块和配对方向；正确性使用 exact 与 IVFFlat top-10 逐行排序比较。生命周期问题单独使用 1,000/10,000/50,000 rescans 的五次消融，不将其执行时间混入 SIMD 主结论。

图表脚本必须直接读取归档 CSV/JSON。每张图在图注中注明 run id、输入文件和是否为主结论。逐查询 P95/P99 未采集，不能从均值推导。

5. 实现与架构

实现分为 rescan 生命周期、自动向量化构建链和查询排序内存控制三条路径。前两条构成主要贡献；第三条作为辅助控制保留。详细文件映射见 `patches/README.md`、`patches/series/` 和 `claim_validation.md`。最终版应补充源码行号、补丁 SHA256 和简化调用链图。

6. 实验设计

主 workload 为 100,000 行、128 维、200 条固定 Cosine 查询，lists=probes=1000。比较 scalar 与恢复自动向量化后的构建，五次 ABBA 配对。辅助矩阵覆盖 query sort memory 与 rescan 次数；回归覆盖 L2/IP/Cosine 和 iterative scan。完整命令见 [artifacts/experiment/ivfflat-query-path-v1/commands/](#)。

7. 结果与图表

已确认数字

指标	基线	优化	变化
200-query workload	20,261.376 ms	16,552.993 ms	-18.30%
QPS	9.871	12.082	+22.40%
recall@10	-	1.000000	2,000 行零差异
内积 self-time 合计口径	32.80%	17.37%	相对降低约 47.04%
query_work_mem 64MB	15,626.188 ms	14,482.277 ms	-7.32%


这里的 32.80% 和 17.37% 都是内积核心符号及其 wrapper 的合计口径，不是单一符号的 self-time。

已生成图


- 1. report/figures/output/01_rescan_memory.svg : rescan 内存消融，源数据为 report/figures/data/rescan_memory.csv。
- 2. report/figures/output/02_simd_pairs.svg : 五次 scalar/vectorized 配对，源数据为 report/figures/data/simd_matrix.csv。
- 3. report/figures/output/03_perf_hotspots.svg : 32.80% 到 17.37% 的 perf 合计口径，源数据为 report/figures/data/perf_hotspots.csv。
- 4. report/figures/output/04_temp_blocks.svg : 69,400 到 0 的临时写块对照，源数据为 report/figures/data/query_work_mem.csv。

四张图均由对应脚本生成；旧 docs/figures/ 图不属于正文证据。


正文图表




Every paired run is faster after restoring auto-vectorization



The inner-product hotspot shrinks after vectorization



Query-specific memory removes temporary I/O



8. 局限与风险

- 主性能结果只覆盖固定 Cosine、高 probes、单机环境和 200 条查询；不能泛化到所有距离类型、数据分布、并发度或分布式拓扑。
- 本轮没有逐查询 P95/P99，延迟结论是五次完整 workload 的均值。
- 50,000 rescans 的内存消融证明峰值增长下降，但执行时间 mixed，不支持生命周期延迟收益。
- query_work_mem 的 7.32% 改善低于 10% 门槛。
- 第一次 SIMD 矩阵因主机负载变化被排除，稳定矩阵才用于 headline。
- 官方 pgvector 44 个 TAP 用例在 OpenTenBase 框架级不可运行：0 个通过、1 个 bailout、43 个未执行；不能写成 44 个失败。

9. 贡献与后续计划

已完成的交付是可移植补丁系列、回归用例、固定数据和原始日志、性能矩阵、正确性证明及 Draft PR #1。后续优先级是完成 PDF 和图表，再将 PR 补齐结果链接并结束 draft 状态；新的排序优化必须另立验收契约，不在当前报告中追加未经验证的收益。

10. 附录与复现命令

主实验入口：`artifacts/experiment/ivfflat-query-path-v1/commands/reproduce-main.md`；smoke
入口：`artifacts/experiment/ivfflat-query-path-v1/commands/reproduce-smoke.md`。复现时先核
对 `run_manifest.json`、数据清单和补丁基线，再执行命令并将新日志写入独立时间戳目录。最终 PDF
附录需嵌入关键命令、SHA256 校验方式和原始证据索引。