

OpenTenBase pgvector 查询路径优化

技术报告与可复现证据包

报告版本 : 2026-08-18 | run id: ivfflat-query-path-v1

1. 摘要

研究问题

本项目针对 OpenTenBase 内置 pgvector 的 IVFFlat

查询路径，研究两个相互独立但会在生产查询中同时出现的问题：重复 rescan

时排序状态和归一化查询值的生命周期是否可靠，以及高 probes 查询是否真正使用了 pgvector

原本设计的自动向量化编译能力。目标是改善稳定性和延迟，同时保持距离计算、索引计划与召回率不变。

方法与证据

源码审计定位到两处平台适配点。第一处在 rescan 生命周期：补丁在重新归一化 Cosine 查询值前释放旧值，并在 OpenTenBase PG10 基座没有 tuplesort_reset()

时采用销毁并重建排序状态的等价语义。第二处在构建链：OpenTenBase 的 in-tree 构建设没有消费 pgvector 的 PG_CFLAGS，导致上游已有的自动向量化参数被静默丢失；补丁恢复实际 CFLAGS 传递，依靠编译器生成 packed SIMD。代码中没有手写 SIMD intrinsics。

主实验固定 100,000 行、128 维、200 条 Cosine 查询，lists=1000、probes=1000、work_mem=4MB，采用五次 ABBA 配对。稳定矩阵显示优化构建平均工作负载从 20,261.376 ms 降至 16,552.993 ms，即降低 18.30%，5/5 配对更快；吞吐从 9.871 QPS 升至 12.082 QPS，即提高 22.40%。2,000 个 exact 与 IVFFlat top-10 结果逐行一致，recall@10=1.000000，差异行数为 0。perf 证据显示内积相关 self-time 合计占比从 32.80% 降至 17.37%，与机制主张一致。

rescan 消融在 10,000 和 50,000 次循环时分别使峰值 RSS 增长降低 48.35% 和 59.97%，但生命周期执行时间方向 mixed，因此不附加延迟收益。新增 ivfflat.query_work_mem=64MB 消除了每个工作负载的 69,000 个临时读块和 69,400 个临时写块，但延迟改善为 7.32%，低于 10% 主成功门槛，故被降级为可选调优控制。

结论

证据支持两项平台级发现：OpenTenBase 的 IVFFlat rescan 需要显式恢复排序状态和查询值生命周期语义；构建链中的一行标志传递差异会让上游自动向量化能力静默失效。主性能结论只适用于本报告固定的高 probes、Cosine、单机 workload；数据分布、距离类型、并发度和分布式拓扑的泛化仍需后续矩阵验证。

2. 背景与任务对齐

2.1 项目背景

OpenTenBase 将 pgvector 作为数据库内向量检索能力的一部分。IVFFlat 查询先按中心距离选择候选 list，再计算候选距离并通过 tuplesort 产生 top-k；当查询出现在嵌套循环或远程执行路径中时，同一个 scan state 会被反复 rescan。该路径同时受到查询值分配、排序状态复用、编译器优化和临时文件 I/O 的影响，单看一次 SQL 延迟无法解释全部风险。

本项目选择源码、编译产物和固定 workload 三层证据：源码确认语义变更，汇编和 perf 确认机制，重复矩阵确认结果大小。这样可以区分“修复正确性问题”“恢复平台能力”和“单纯调大内存参数”三类贡献。

2.2 任务与验收门槛

项目计划 (PLAN.md) 规定：保持固定数据生成方法、查询集合、索引参数、数据库拓扑和预热方式；正式比较至少五次重复；保存 EXPLAIN (ANALYZE, BUFFERS)、回归日志和 recall@10。主性能成功门槛是核心指标至少改善 10%、五次方向一致、召回率不下降且计划继续使用 IVFFlat。

本报告对应的已验收结果如下：

任务	证据	结论
rescan 状态可靠	performance/final-vectorized-regression.log，原始基线 3 个 invalid tuplesort state	回归通过
生命周期内存	ablation/memory-matrix-stats.csv	10,000/50,000 rescans 峰值增长分别降低 48.35%/59.97%
高 probes 延迟	performance/simd-matrix-stability/aggregate.csv	平均降低 18.30%，5/5 更快
正确性与召回	performance/vectorized-matrix/correctness.txt	2,000/2,000 一致，recall 1.0
查询排序内存	performance/query-work-mem-matrix/aggregate.csv	7.32%，低于主门槛，降级记录

2.3 贡献边界

贡献一是 OpenTenBase 对 pgvector rescan 生命周期的兼容修复，包含上游 Fix memory leak in ivfrescan 语义的移植和 PG10 排序 API 差异的独立适配。贡献二是发现并修复 OpenTenBase in-tree 构建链丢失 pgvector 自动向量化标志的问题；结果是编译器自动生成 packed SIMD，而不是新增 intrinsics。贡献三是把性能、正确性、负结果和原始日志放在同一可复现证据链中。

本项目不宣称所有 pgvector workload 都能获得 18.30% 提升，不宣称 lifecycle 修复本身降低执行时间，也不把 7.32% 的排序内存收益包装为主成果。这些限制将在第 8 章展开。

3. 环境与可复现声明

证据来源

- 远端环境：artifacts/experiment/ivfflat-query-path-v1/environment/remote-environment.txt
- 运行契约：artifacts/experiment/ivfflat-query-path-v1/run_manifest.json
- 数据清单：artifacts/experiment/ivfflat-query-path-v1/performance/data/dataset-manifest.md
- 补丁与基线：patches/series/、PLAN.md

固定环境

主实验运行在授权端点 root@45.202.199.140：Linux 3.10.0-1160.80.1.el7.x86_64、4 个 QEMU 虚拟 CPU、3.7 GiB RAM、2.0 GiB swap；编译器为 gcc 11.2.1。OpenTenBase 为 5.0，源码基线为 0915c04e4，pgvector 为 0.8.0；集群拓扑为 GTM 22101、Coordinator 22201、Datanode 22301。这些字段逐项来自 environment/remote-environment.txt，不是运行后手工估算。

数据合同固定为 100,000 条 128 维向量、200 条 Cosine 查询、top-k=10、lists=1000、probes=1000，item seed 为 17、query seed 为 97。run_manifest.json 保存数据文件 SHA256、标量/向量化动态库 SHA256、ABBA 顺序和重复次数；因此更换机器、编译器或查询集合必须产生新的 run id，不能覆盖本次结果。

证据包还包含 performance/SHA256SUMS、回归日志、执行计划、原始 CSV 和 perf 记录。报告中的图表只读取 report/figures/data/ 快照，快照逐字节对应 artifacts/experiment/ivfflat-query-path-v1/performance/ 的原始矩阵。

可复现要求

报告复现必须使用同一数据规模、查询 CSV、lists/probes、预热策略和五次 ABBA 顺序。若机器、编译器或拓扑改变，结果应作为新 run 归档，不覆盖本 run。

4. 方法学

本项目先做源码审计，再做机制验证，最后才执行性能比较。这样可以把“修复了什么”和“快了多少”分开：`claim_validation.md` 为每条结论定义验收门槛、观测值和 verdict；未达门槛的结果保留为负结果，而不是改写成主贡献。

主性能实验采用五次 ABBA 配对。每个重复都运行完整的 200-query workload，并保存 scalar/vectorized 动态库身份、系统负载快照、平均耗时、临时块和 QPS。ABBA 顺序将变体交错，降低单向热身或主机负载漂移的影响；第一轮跨过负载档位的尝试被单独归档并排除，稳定性复跑才进入 headline CSV。

正确性不是以均值代替：L2、Inner Product、Cosine 和 iterative scan 回归必须通过；另将 exact top-10 与 IVFFlat top-10 排序后逐行比较。最终 2,000 行结果零差异，recall@10 为 1.0。rescan 生命周期单独做 1,000、10,000、50,000 次的五重复消融，以执行期 peak RSS 比较 full patch 与 sort-reset/no-cleanup 变体，不把混合的生命周期执行时间包装成延迟收益。

图表脚本从归档 CSV 读取，不从 PDF 反向抄数。每张图的数据快照、生成脚本、SVG 和 PNG 同时入库，并在报告绑定表中标明 run id 与用途。逐查询 P95/P99 未采集，本报告只宣称五次完整 workload 的均值；不能由均值推导尾延迟。

5. 实现与架构

实现分成三个互相独立的控制面：rescan 生命周期、构建链编译标志和查询排序内存。规范交付补丁为 patches/0001-ivfflat-query-path-optimization.patch，基线是 0915c04e457f9b5625bd2ae71938f13e5e451888，补丁 SHA256 为 c758913d94d21f9fa80472c79a764ea58b4776f1cd8bfb591a6d940a62a9050d。patches/series/ 将同一变更拆成五个可审查提交：修复 IVFFlat scan lifecycle、增加 query sort memory control、恢复自动向量化 flags、增加 rescan 回归覆盖、增加 profiling harness。

rescan 路径对应 ivfscan.c 的查询值生命周期和 tuplesort 批次状态。OpenTenBase PG10 没有上游 tuplesort_reset()，所以实现采用销毁并重建 tuplesort 状态恢复等价的“每批独立排序”语义；Cosine 归一化查询值在下一次 rescan 前释放上一轮分配。回归 SQL 通过 nested-loop/LATERAL 触发多次 IVFFlat loop，避免只测单次扫描。

构建链路径不是新增 intrinsics。上游 pgvector 已提供自动向量化编译参数，但 OpenTenBase in-tree 构建设没有消费 PG_CFLAGS；Makefile 修复只恢复 CFLAGS 传递，最终由 gcc 生成 packed SIMD。汇编证据中 scalar 为 vfmadd231ss，修复后出现 vfmadd231ps，源码没有 __mm* 或 __m* 手写向量指令。

查询排序路径新增 ivfflat.query_work_mem，默认继承 work_mem，仅在用户显式配置时增加 IVFFlat 内部 tuplesort 预算。它消除了临时块，但 7.32% 改善低于预设 10% 门槛，因此被保留为辅助控制，不改变主结论。

6. 实验设计

实验在执行前先冻结门槛和数据合同。主 workload 为 100,000 行、128 维、200 条固定 Cosine 查询，lists=probes=1000，五次 ABBA 配对；主成功门槛为至少 10% 的同向改善、正确性回归通过、recall 不下降。这个门槛来自 PLAN.md，不是观察到结果后倒推出来的。

主比较只改变动态库构建变体：scalar 对照保留原始自动向量化参数失效状态，vectorized 变体应用 Makefile 修复。每格保存完整 workload 日志、系统快照、库文件哈希和计划证据。五个配对均更快，均值从 20,261.376 ms 降到 16,552.993 ms；同时 exact 与 IVFFlat top-10 的 2,000 行逐行一致。

辅助实验包含两条独立线。rescan 消融使用 1,000/10,000/50,000 次重复并比较 peak RSS；query sort memory 使用 4 MB 与 64 MB 两档，观察临时块是否消失。L2/IP/Cosine 与 iterative scan 回归用于防止优化改变距离或扫描语义。完整命令和原始输出位于 artifacts/experiment/ivfflat-query-path-v1/commands/、logs/ 和 performance/。

报告明确排除三种过度解释：生命周期执行时间方向混合，不称为延迟收益；query-specific memory 只有 7.32%，低于 10% 门槛，不称为主加速；单机、固定 Cosine、高 probes 结果不能外推到其他距离、并发或分布式拓扑。

7. 结果与图表

已确认数字

指标	基线	优化	变化
200-query workload	20,261.376 ms	16,552.993 ms	-18.30%
QPS	9.871	12.082	+22.40%
recall@10	-	1.000000	2,000 行零差异
内积 self-time 合计口径	32.80%	17.37%	相对降低约 47.04%
query_work_mem 64MB	15,626.188 ms	14,482.277 ms	-7.32%


这里的 32.80% 和 17.37% 都是内积核心符号及其 wrapper 的合计口径，不是单一符号的 self-time。

已生成图


- 1. report/figures/output/01_rescan_memory.svg : rescan 内存消融，源数据为 report/figures/data/rescan_memory.csv。
- 2. report/figures/output/02_simd_pairs.svg : 五次 scalar/vectorized 配对，源数据为 report/figures/data/simd_matrix.csv。
- 3. report/figures/output/03_perf_hotspots.svg : 32.80% 到 17.37% 的 perf 合计口径，源数据为 report/figures/data/perf_hotspots.csv。
- 4. report/figures/output/04_temp_blocks.svg : 69,400 到 0 的临时写块对照，源数据为 report/figures/data/query_work_mem.csv。

四张图均由对应脚本生成；旧 docs/figures/ 图不属于正文证据。


正文图表




Every paired run is faster after restoring auto-vectorization



The inner-product hotspot shrinks after vectorization



Query-specific memory removes temporary I/O



8. 局限与风险

- 主性能结果只覆盖固定 Cosine、高 probes、单机环境和 200 条查询；不能泛化到所有距离类型、数据分布、并发度或分布式拓扑。
- 本轮没有逐查询 P95/P99，延迟结论是五次完整 workload 的均值。
- 50,000 rescans 的内存消融证明峰值增长下降，但执行时间 mixed，不支持生命周期延迟收益。
- query_work_mem 的 7.32% 改善低于 10% 门槛。
- 第一次 SIMD 矩阵因主机负载变化被排除，稳定矩阵才用于 headline。
- 官方 pgvector 44 个 TAP 用例在 OpenTenBase 框架级不可运行：0 个通过、1 个 bailout、43 个未执行；不能写成 44 个失败。

9. 贡献与后续计划

本项目形成三项可核验贡献。第一，补齐 OpenTenBase PG10 上 IVFFlat rescan 的排序状态与 Cosine 查询值生命周期语义，并以 nested-loop 回归和 peak RSS 消融证明边界。第二，发现 OpenTenBase in-tree 构建链静默丢失 pgvector 既有自动向量化参数，恢复 CFLAGS 传递后在不写 intrinsics 的前提下获得 5/5 同向、平均 18.30% 的高 probes

加速。第三，把源码、变体哈希、固定数据、原始日志、负结果和生成脚本放入同一证据链；G12、正确性和 recall 门槛均有独立文件支撑。

上游投递计划（G20）分两步执行。首先在本仓库完成 Draft PR #1

的公开评审痕迹，标题与正文只描述源码改动和可复现实验，不把 AI 工具写进标题；正文链接本报告、补丁 SHA256、回归日志和限制章。其次从 patches/series/ 导出最小 git format-patch，以基线 0915c04 做 git apply --check，再分别向 OpenTenBase 维护渠道和 pgvector 上游提交适配说明。rescan 的上游语义来源为 pgvector commit 93a5b4a16d699eaf890970777c19f19b9d545782；tuplesort 重建和 Makefile CFLAGS 传递属于 OpenTenBase 平台适配，投递时会拆成独立说明，避免把平台差异伪装成上游已有行为。

后续只保留已定义验收契约的工作：补充跨距离与多拓扑矩阵、完成 W3 构建耗时观测，并在证据充分后制作 PPT。新的排序优化若没有单变量实验、5 次重复和 recall 证据，不并入本报告。

10. 附录与复现命令

主实验入口：`artifacts/experiment/ivfflat-query-path-v1/commands/reproduce-main.md`；smoke 入口：`artifacts/experiment/ivfflat-query-path-v1/commands/reproduce-smoke.md`。复现时先核对 `run_manifest.json`、数据清单和补丁基线，再执行命令并将新日志写入独立时间戳目录。最终 PDF 附录需嵌入关键命令、SHA256 校验方式和原始证据索引。

证据索引

证据层	文件	证明内容	使用边界
源码交付	<code>patches/0001-ivfflat-query-path-optimization.patch</code>	完整源码差异与 canonical SHA256	以 0915c04 为基线应用
分步审查	<code>patches/series/0001..0005</code>	五个可独立审查的变更单元	不与历史单用途 patch 混合
环境	<code>artifacts/.../environment/remote-environment.txt</code>	CPU、内存、编译器、版本、拓扑	更换端点需新 run
正确性	<code>performance/final-vectorized-regression.log</code> 、 <code>correctness.txt</code>	回归通过、2,000 行 top-10 零差异	不替代多距离完整矩阵
性能	<code>performance/simd-matrix-stability/aggregate.csv</code>	五次 ABBA、每格耗时和方向	只支撑固定 Cosine/high-probes
机制	<code>performance/*/perf-report-symbol.txt</code>	内积热点与自动向量化命中	不是跨 CPU 架构结论
负结果	<code>claim_validation.md</code> 、 <code>DECISION.md</code>	7.32% 辅助改善、首轮排除理由	不包装为主成果

复现顺序

- 检出 `muzimu217/ivfflat-query-path-optimization` 分支，确认工作树干净。
- 对 canonical patch 执行 `sha256sum`，再对 OpenTenBase 基线执行 `git apply --check`。
- 按 `reproduce-smoke.md` 编译 `pgvector`，运行 `ivfflat_vector` 回归和 `nested-loop rescan`；保存计划，确认实际出现多次 IVFFlat loop。
- 生成固定 item/query 数据，核对 seed、行数、维度、lists/probes 与 manifest；任何字段变化都增加 run id。
- 交错运行 scalar/vectorized 五次 ABBA，保留每次系统负载快照、动态库哈希和完整 workload 日志。
- 运行 `python3 report/figures/scripts/01_rescan_memory.py` 到 `04_temp_blocks.py`，再用 `PYTHON_BIN=python3 bash report/build.sh` 生成 PDF；在 `report/build/` 内执行 `shasum -a 256 -c SHA256SUMS`。

结果复核清单

检查	预期	原始来源
回归	1/1 pass，L2/IP/Cosine/iterative scan 无 diff	<code>final-vectorized-regression.log</code>
配对方向	5/5 vectorized 更快，最低配对收益 11.64%	<code>simd-matrix-stability/aggregate.csv</code>
吞吐	9.871 → 12.082 QPS	<code>metrics.md</code>
正确性	2,000/2,000，differing rows=0，recall=1.0	<code>correctness.txt</code>

检查	预期	原始来源
临时块	query_work_mem 64 MB 时写块 69,400 → 0	query-work-mem-matrix/aggregate.csv
生命周期	50,000 rescans peak growth 下降 59.97%	ablation/memory-matrix-aggregate.csv

任何一项不满足时，复现报告必须保留失败日志并将 claim 标为 **inconclusive**；不能只保留成功的截图。

稳定矩阵逐对记录

Pair	Scalar ms	Vectorized ms	Improvement
1	21,523.297	16,592.661	22.91%
2	21,286.304	17,018.814	20.05%
3	21,288.003	17,341.879	18.54%
4	19,776.652	17,474.843	11.64%
5	17,432.626	14,336.769	17.76%

每行的 `index_loops=200`，临时块读/写均为 69,000/69,400；因此这张表只隔离编译变体，不能把临时 I/O 的变化误归因于自动向量化。动态库 SHA256 在 `run_manifest.json` 中固定，表中数字来自 `simd_matrix.csv`，不是从图像识别得到。

生命周期消融原始摘要

Rescans	Full patch peak KB	No-cleanup peak KB	Reduction	Full time ms	No-cleanup time ms
1,000	4,490.4	4,768.8	5.84%	39.217	42.219
10,000	9,803.2	18,980.8	48.35%	376.420	404.121
50,000	33,521.6	83,732.8	59.97%	2,103.502	2,035.270

最后一列解释了为什么报告不宣称生命周期延迟收益：执行时间方向并不稳定，而 `peak RSS` 的趋势稳定。这个负结果与主性能矩阵共享同一主机和固定数据，但使用独立变体，避免把两个机制混为一谈。

11. 证据附录

门禁与文件绑定

门禁	通过条件	结果	绑定证据
G12 性能	五次配对同向且平均改善至少 10%	通过，18.30%，5/5	metrics.md、simd_matrix.csv
Recall	exact 与 IVFFlat top-10 逐行一致	通过，2,000/2,000	correctness.txt
回归	新增 rescan 回归无 diff	通过，1/1	final-vectorized-regression.log
机制	汇编出现 packed SIMD，且无手写 intrinsics	通过，vfmadd231ps	scalar/vectorized perf report
负结果	低于门槛的优化不进入主结论	通过，7.32% 降级	claim_validation.md、DECISION.md

变体身份

标量动态库 SHA256 为 0a83133b5dc6ba732f06eaf33da841f27b030086f720416972b3da9f6c62fb77，向量化动态库 SHA256 为 c1fb401096b457ab2485c294da98fc803eed6097225b7d3c8ef44d8cd92e0c7d。两者来自同一数据合同和同一端点；变体身份在每个重复的日志前置段和 run_manifest.json 中重复记录。

解释边界

主性能结果是完整 200-query workload 的均值，不能被改写为逐查询尾延迟。高 probes、Cosine、单机拓扑是结论适用域；L2/IP/iterative scan 的回归通过只证明结果保持正确，不证明它们也获得 18.30% 加速。rescan peak RSS 消融证明生命周期修复降低执行期峰值，但其执行时间 mixed，因此不与 SIMD 延迟结果合并。

交付再现

提交者可以从 patches/README.md 取得 canonical patch 和五件套 series，从 artifacts/experiment/ivfflat-query-path-v1/commands/ 取得命令，从 report/figures/scripts/ 重生成图表，从 report/build.sh 生成 PDF。任何新机器必须在报告外创建新的 run 目录，并同时提交环境、数据、动态库和原始日志哈希；不得覆盖本附录绑定的证据。